Генеративные модели Computer Vision

Угадай семейство моделей

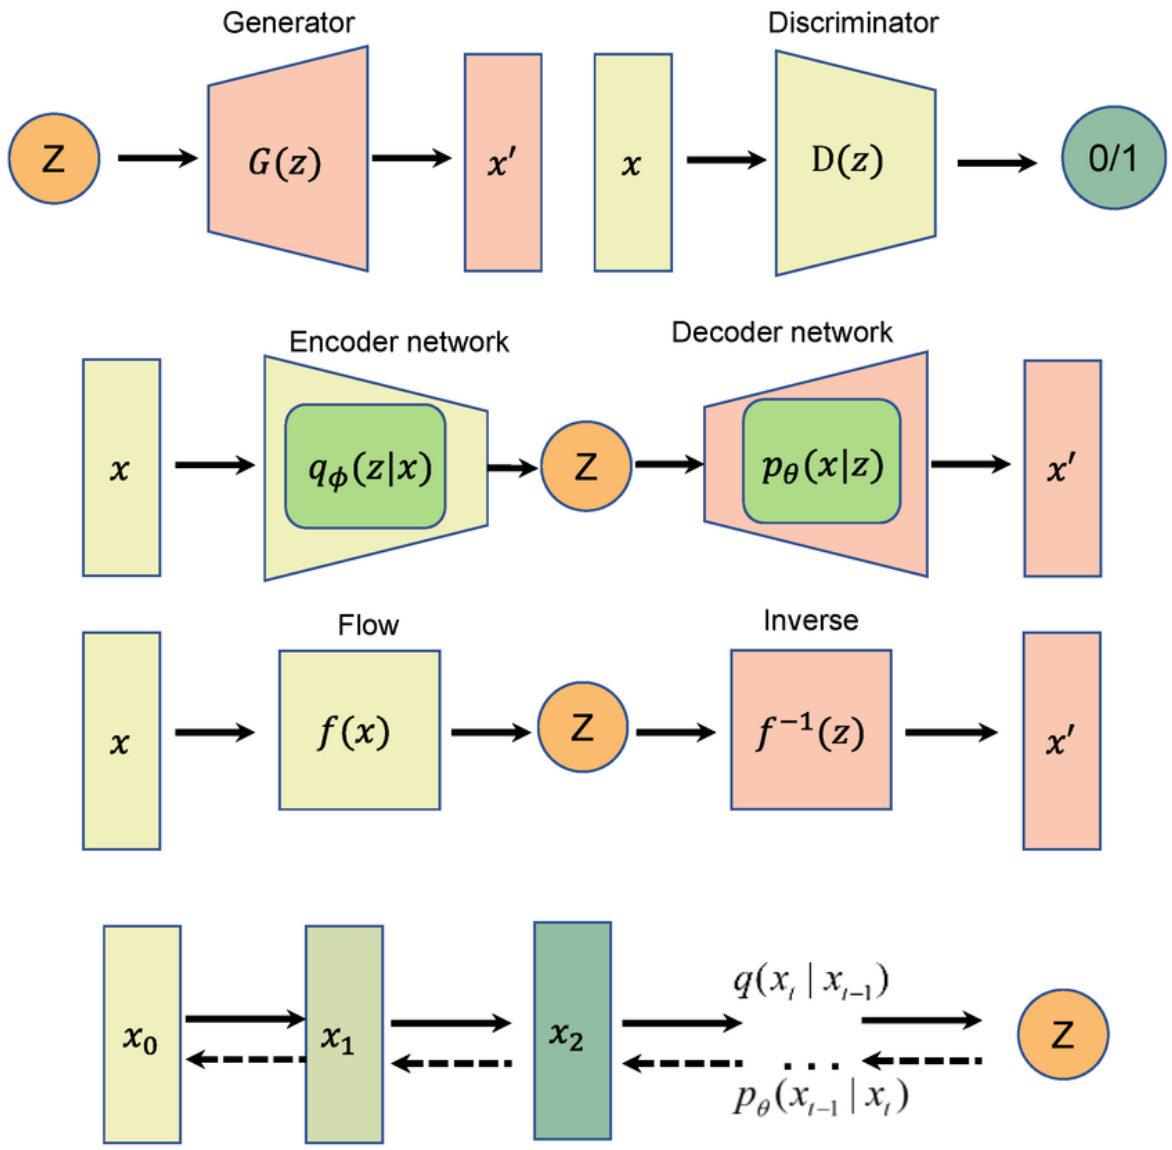

Generative learning trilemma

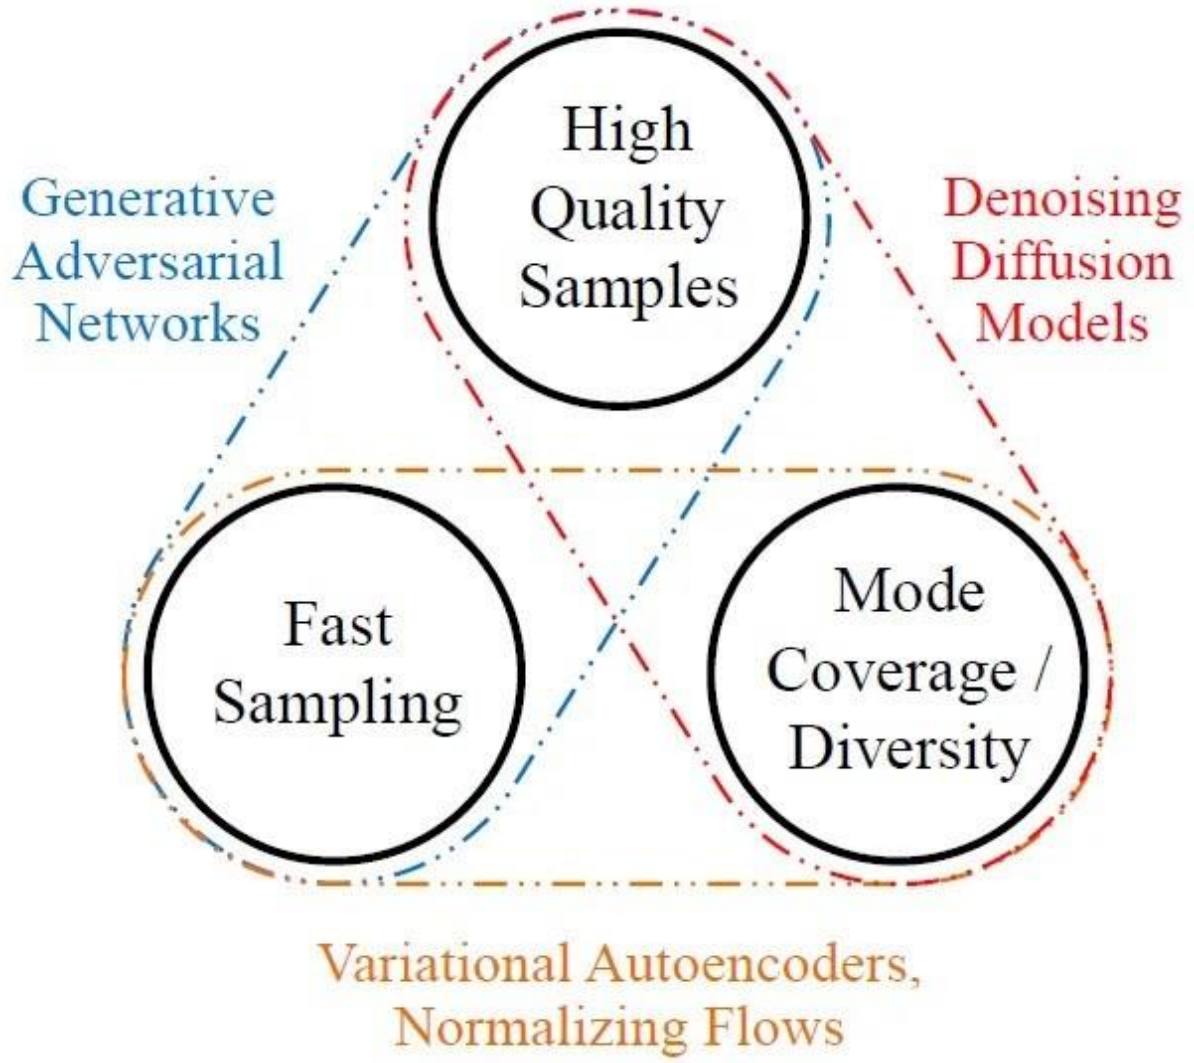

Source: https://zhuanlan.zhihu.com/p/503932823

Stable Diffusion (Diffusion + VAE + CLIP)

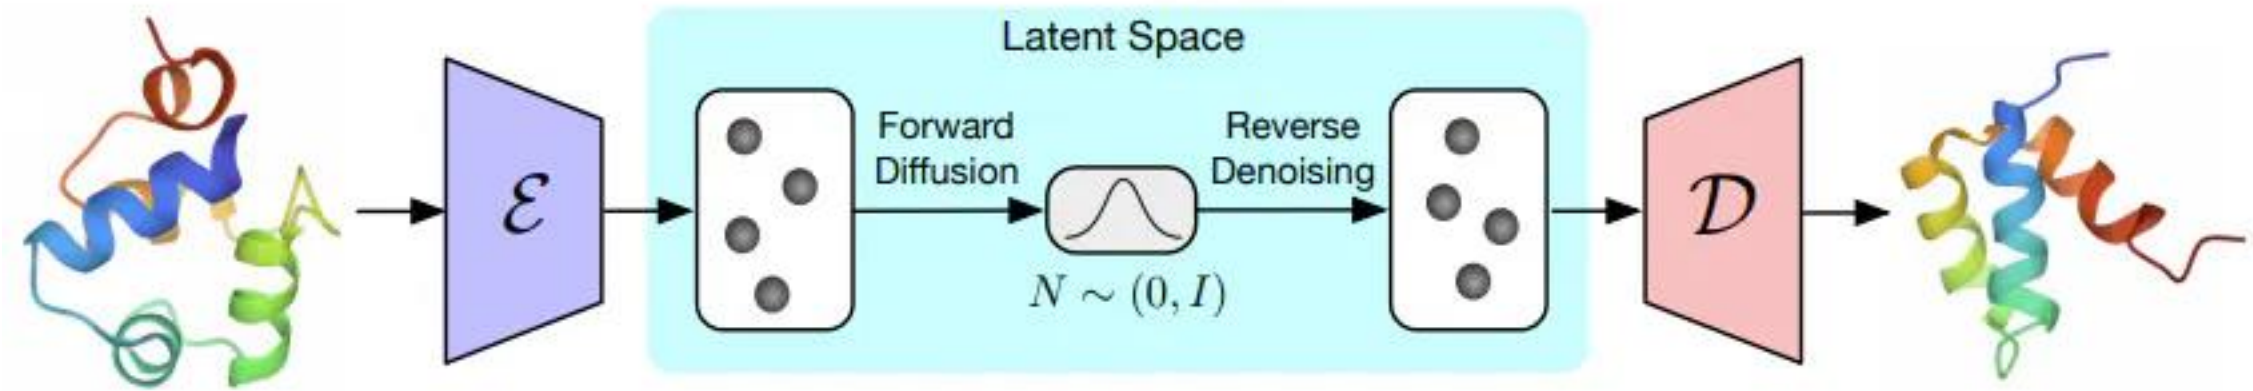

Добавление CLIP-эмбеддингов

Cross-attention:

- У нас есть внутренние представления картинки на текущем шаге диффузии (features)
- У нас есть CLIP-эмбеддинг текста (тоже в виде векторов)

UNet делает cross-attention:

- Для каждого «пиксельного» или patch-представления картинки
- Смотрит на все векторы из текстового эмбеддинга
- Решает, какая часть текста важна для этого участка изображения

Модель взвешивает информацию из текста и картинки, чтобы обновить шум так, чтобы он стал ближе к описанию.

Добавление CLIP-эмбеддингов

1.Queries (Q) — это патчи картинки (текущие feature-векторы в UNet на шаге диффузии).

- Каждая маленькая часть картинки “спрашивает”: «На что из текста мне обратить внимание?»

2.Keys (K) и **Values (V)** — это векторы слов из CLIP-эмбеддинга текста

- Каждое слово текста превращается в вектор.
- Keys отвечают за «идентификацию важности слова», Values — за информацию, которую можно использовать.

3. **Attention**:

1. Для каждого патча Query считается вес сходства с каждым Key → softmax → веса внимания
2. Query суммирует Values, взвешенные этими коэффициентами → обновляет патч картинки

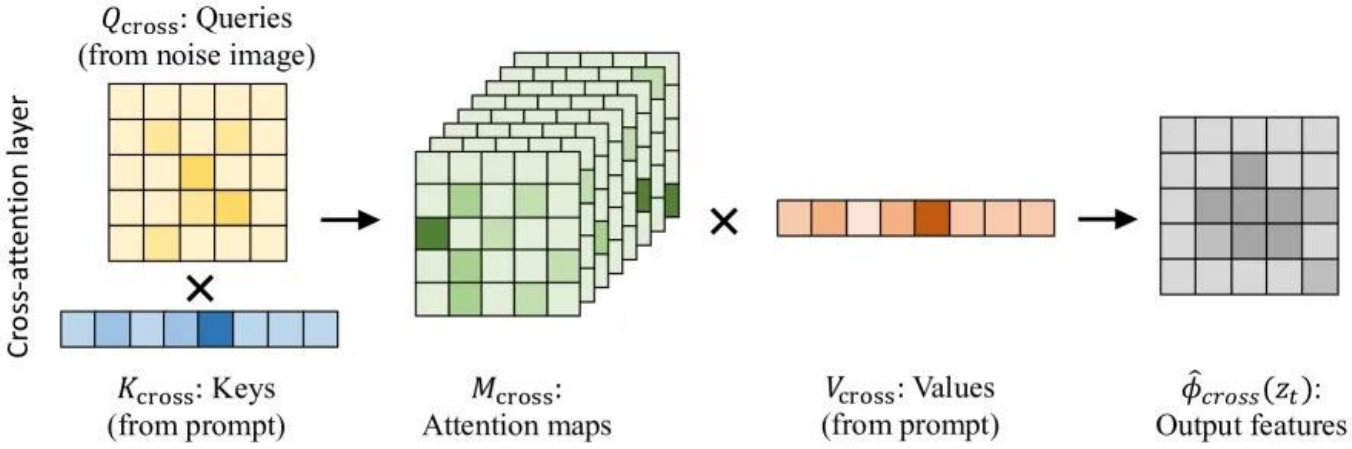

Classifier quidance

Часто генерация по промпту бывает неуверенной или нечеткой.

Можно дополнительно обучить классификатор, который будет определять уверенность модели в сгенерированном классе и на каждой итерации генерации сдвигать результат в сторону нужного класса.

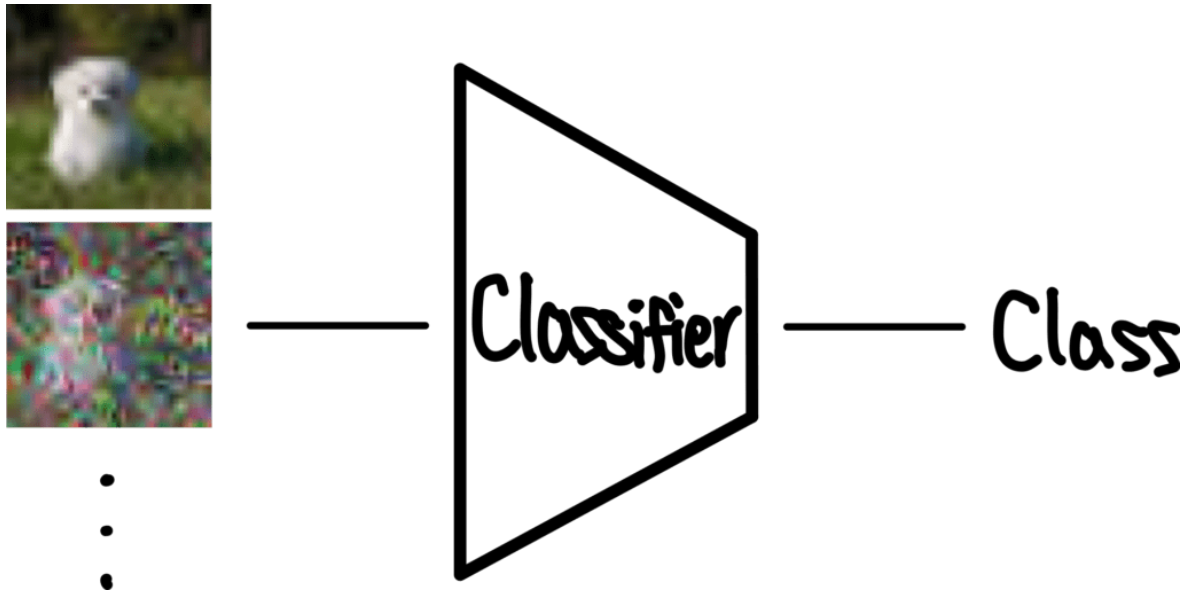

Classifier quidance: применение

Часто генерация по промпту бывает неуверенной или нечеткой.

Можно дополнительно обучить классификатор, который будет определять уверенность модели в сгенерированном классе и на каждой итерации генерации сдвигать результат в сторону нужного класса.

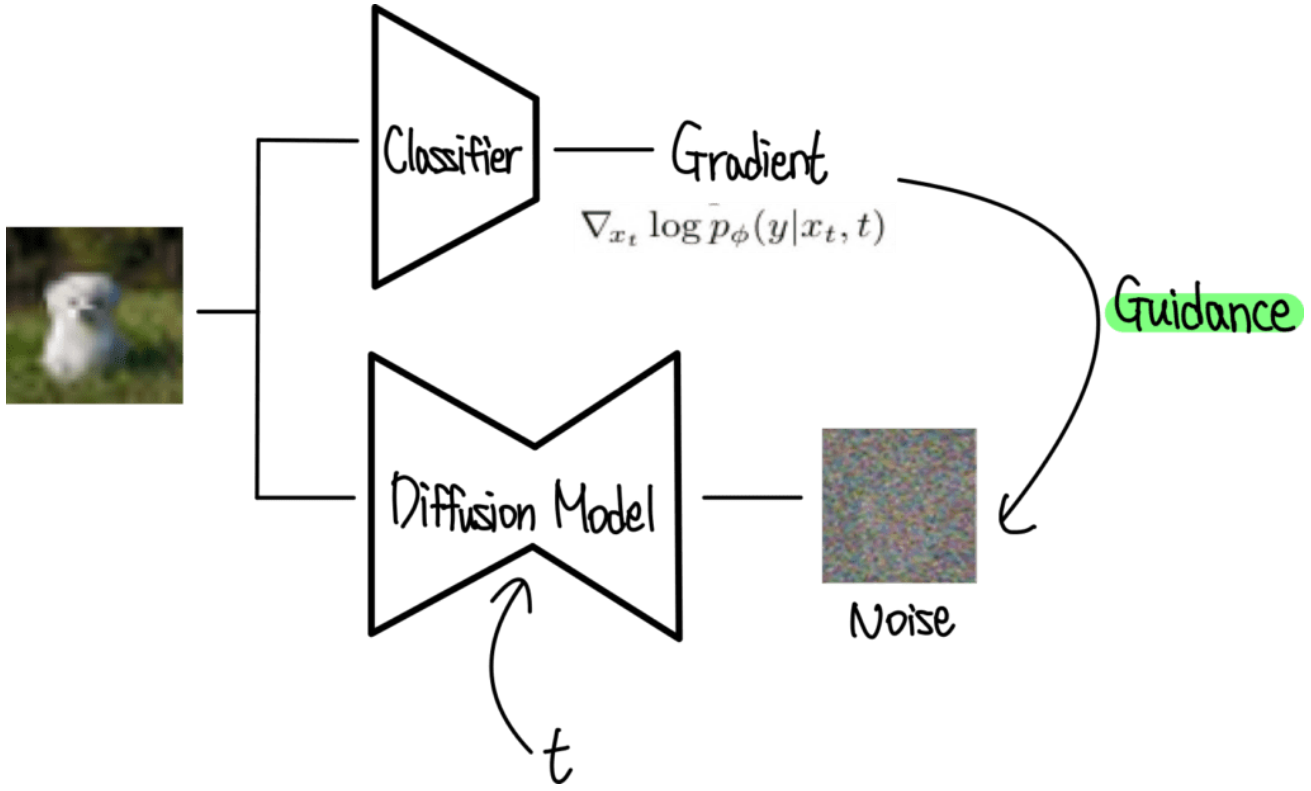

Classifier-free guidance (CFG)

На этапе обучения модели с некоторой небольшой фиксированной вероятностью мы подаем пустой промпт (вместо изначального промпта)

В диффузионных моделях **CFG** позволяет управлять генерацией изображения по тексту **без отдельного классификатора**, используя один и тот же шумовой предсказатель:

$$\hat{\epsilon} = \epsilon_\theta(x_t) + w \cdot (\epsilon_\theta(x_t, c) - \epsilon_\theta(x_t))$$

- $\epsilon_\theta(x_t, c)$ — предсказание модели с условием c (текст).
- $\epsilon_\theta(x_t)$ — предсказание модели **без условия** (пустой промпт).
- w — коэффициент “guidance scale”, который усиливает влияние текста.

Classifier-free quidance (CFG)

На этапе обучения модели с некоторой небольшой фиксированной вероятностью мы подаем пустой промпт (вместо изначального промпта)

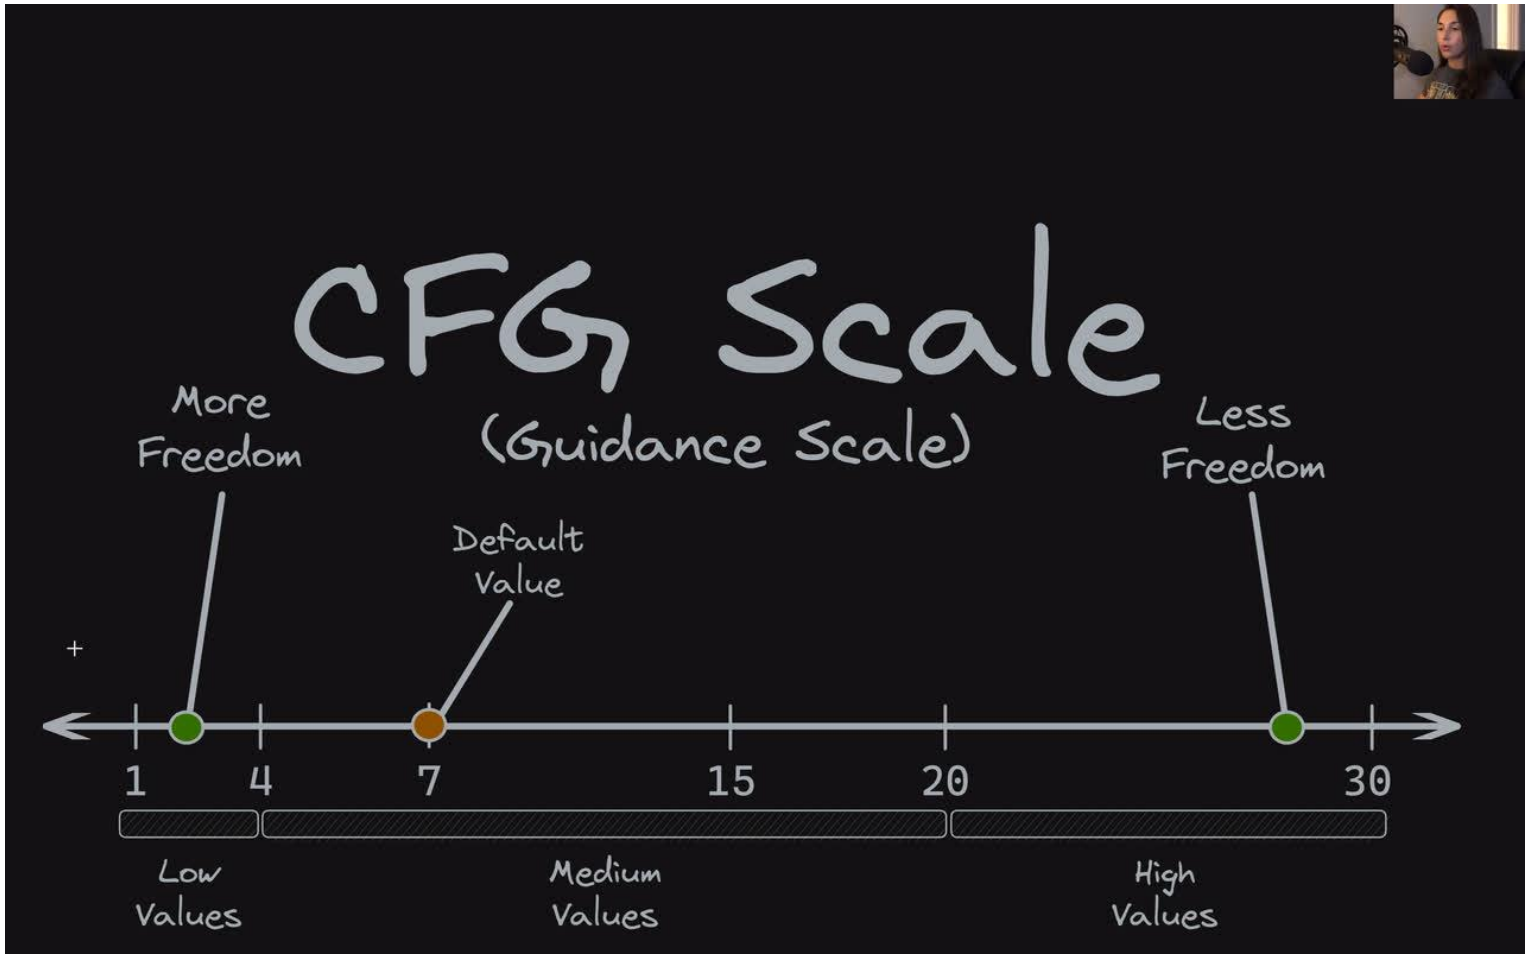

Практика по Stable Diffusion

https://colab.research.google.com/drive/1evC2-9flfkMOchqZuYQ2fgKWWUbHqpxb?usp=sharing

Timeline генеративных CV-моделей

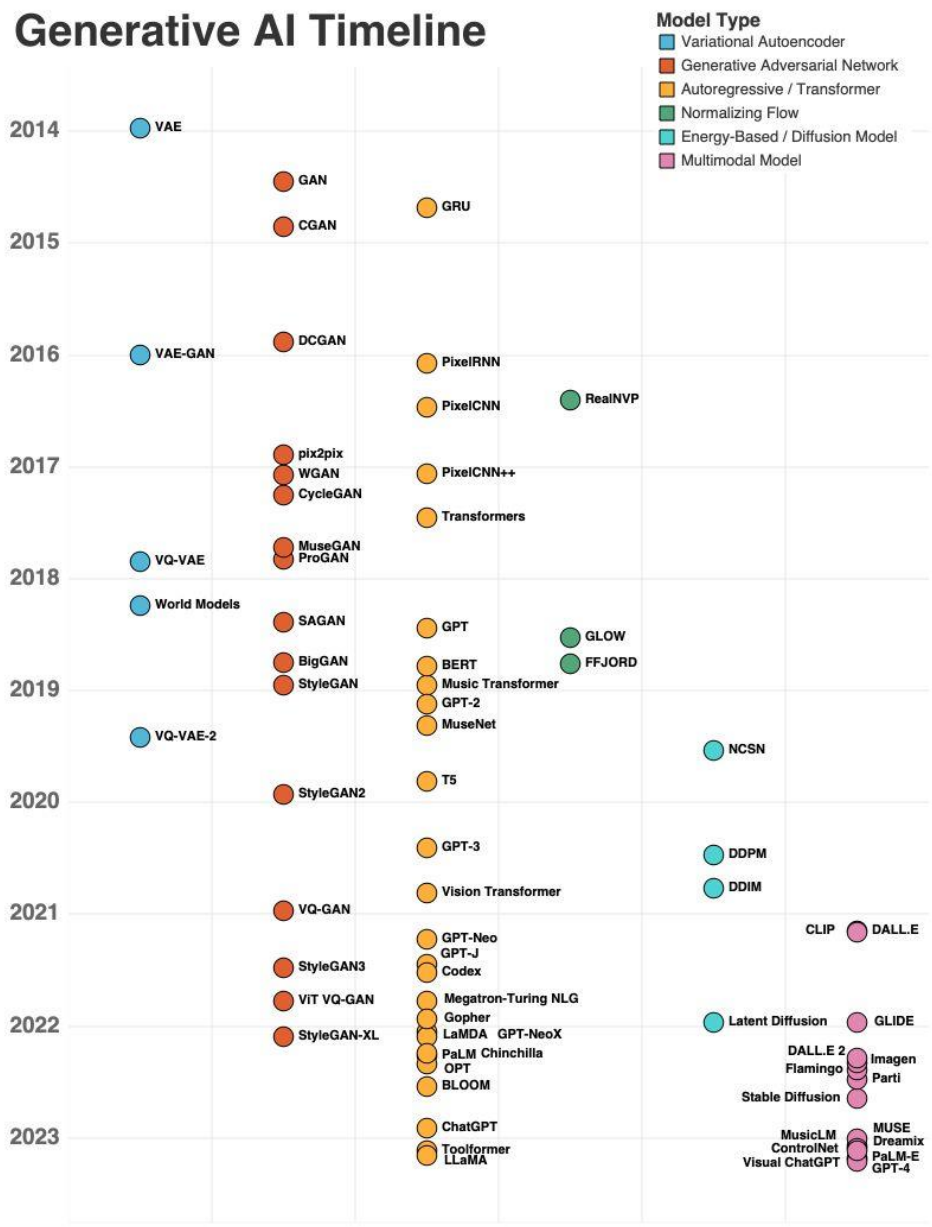

Авторегрессионные модели

Идея AR-моделей

Авторегрессионные модели (как и в NLP) учатся прогнозировать кусочки изображения “токен за токеном”

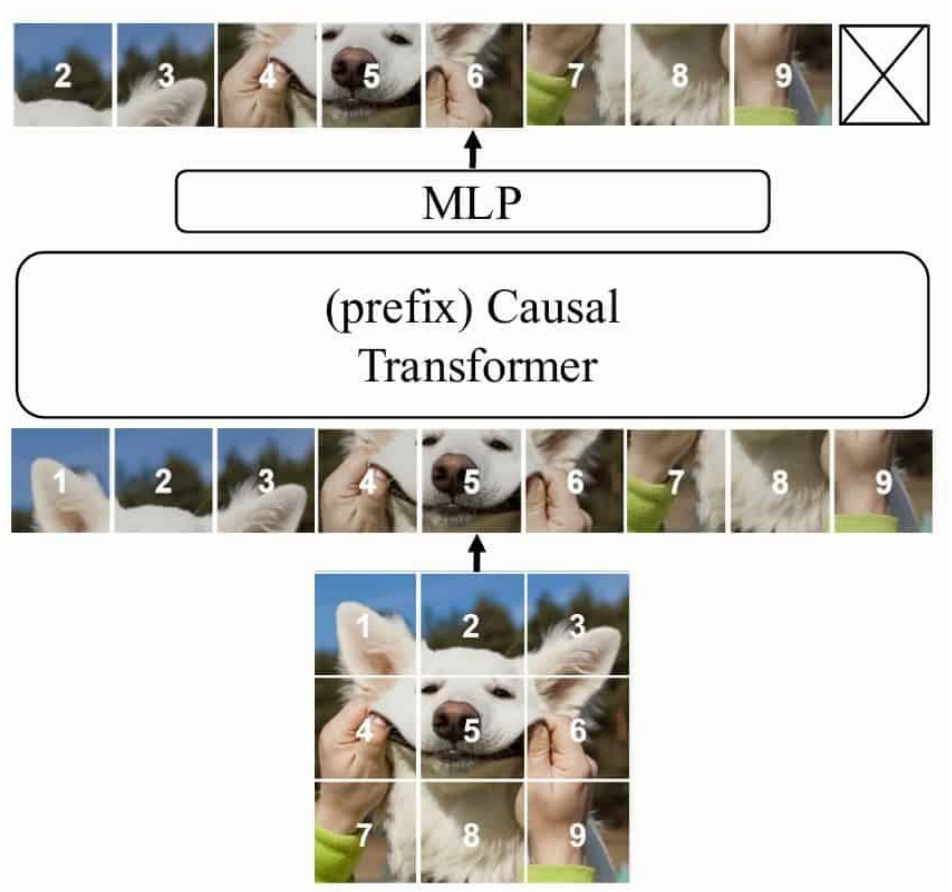

Идея AR-моделей

Токен картинки (или же patch) – это кусочек изображения, одна “клеточка”.

- Изображение разбивается на патчи, затем эти патчи векторизуются (для каждого патча модель выучит числовой вектор-embedding) и подаются в модель

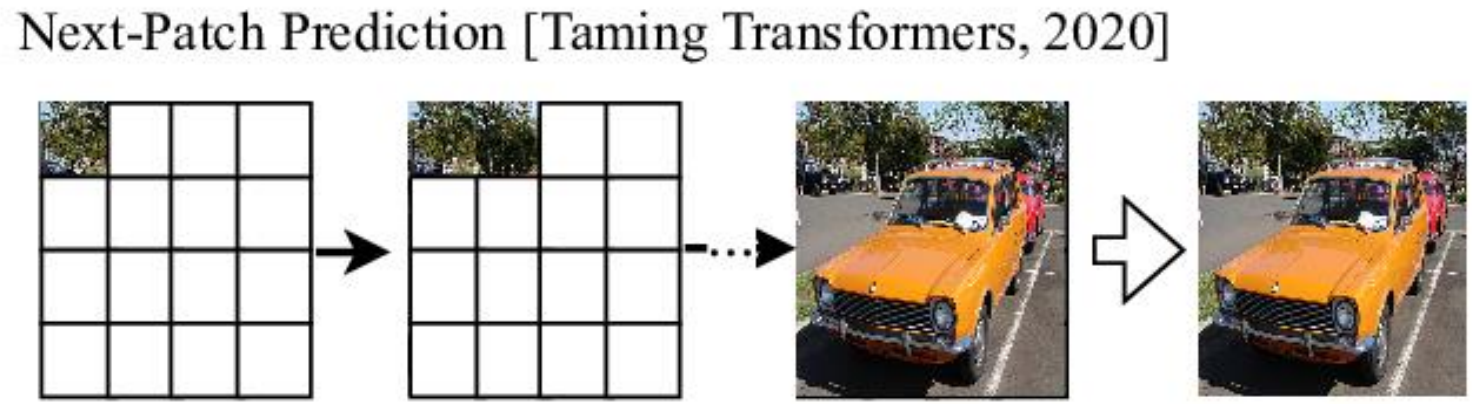

Сравнение AR-моделей с Stable Diffusion

Model	Quality	Diversity	Speed
AR (modern)	9.5	7	8
Diffusion (Stable Diffusion XL)	8.5	9	6

- **AR:** Best visual quality and structural consistency
- **Diffusion:** More diverse outputs
- **AR:** Faster with parallel decoders

Типы архитектур

- **PixelAR / PixelCNN / PixelRNN**
  - Генерируют изображение пиксель за пикселем
  - Медленно генерируют и редко используются сейчас

- **VQ-AR (через токены)**
  - Изображение разбивают на токены
  - Потом Transformer генерирует эти токены один за другим
  Пример: DALL·E 1, RQ-Transformer

- **Иерархический подход**
  - Сначала модель генерирует крупные “размытые” блоки
  - Потом в несколько шагов уточняет их содержимое

Vision Transformer (аналог BERT)

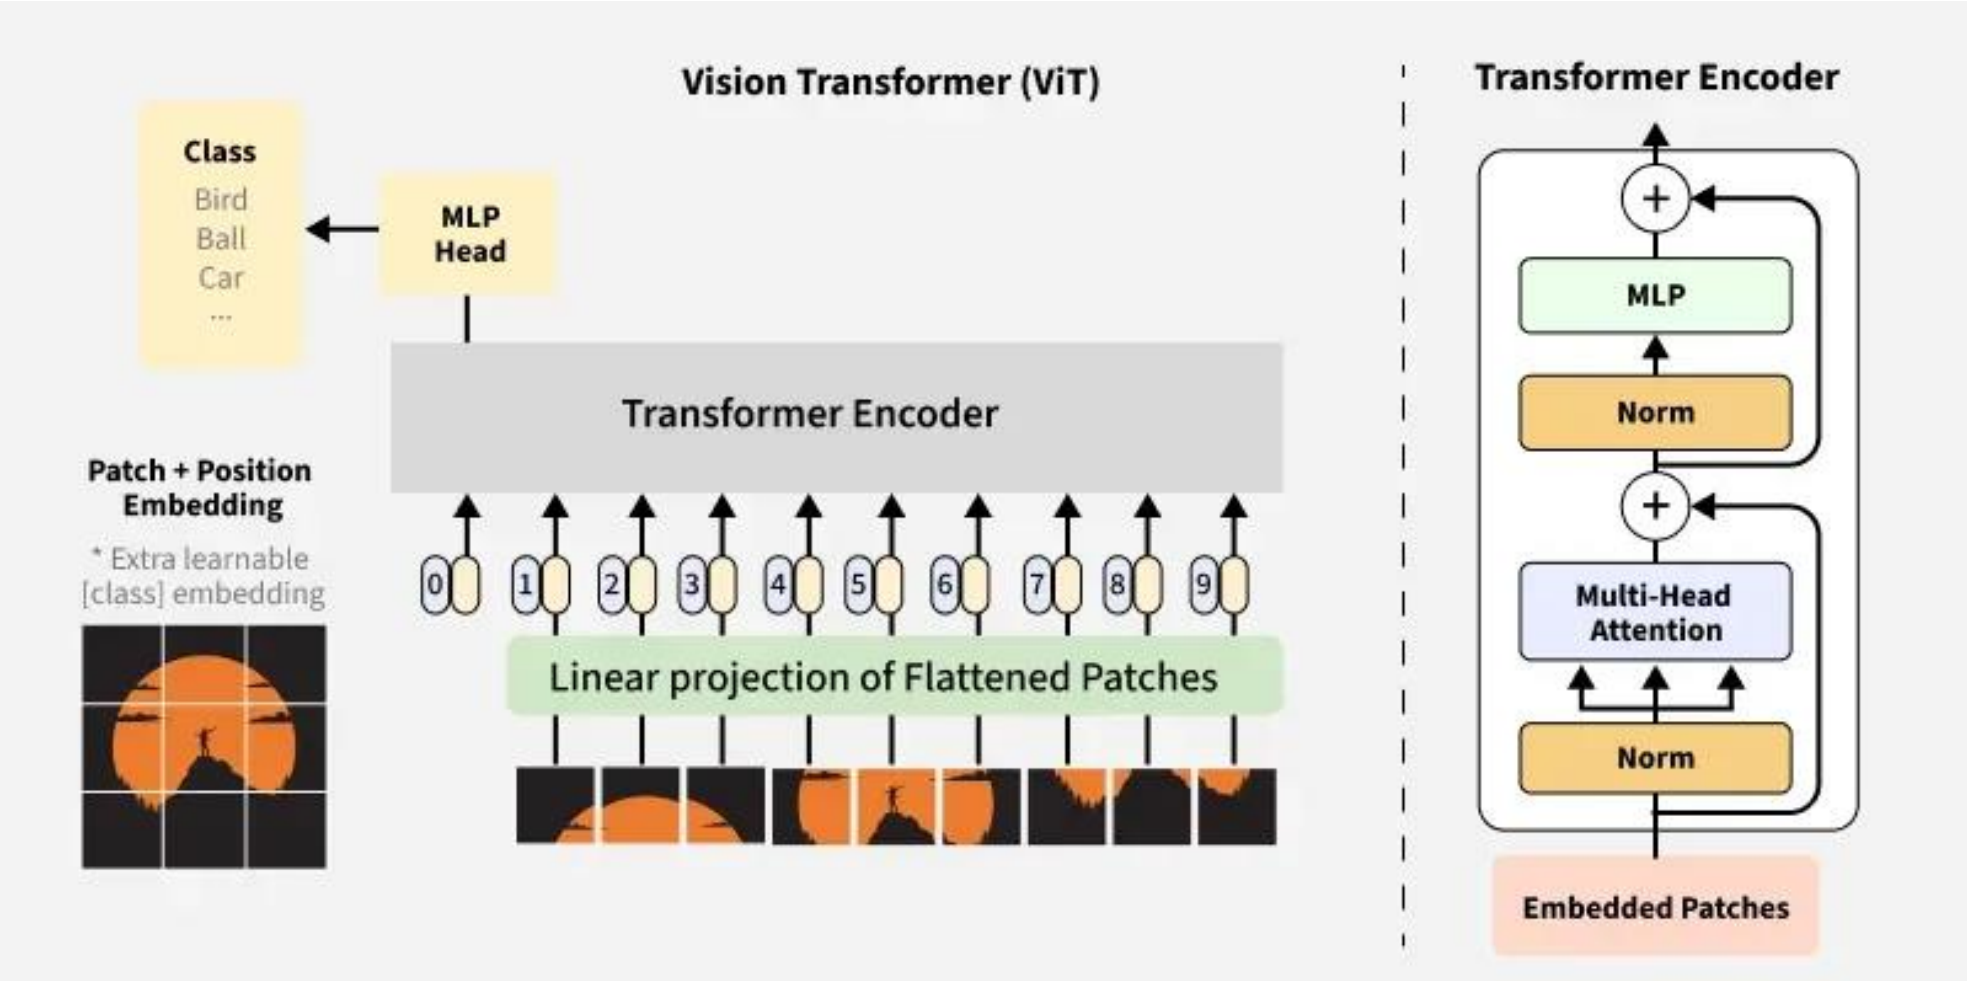

Vector Quantized AR-model, VQ-AR (аналог GPT)

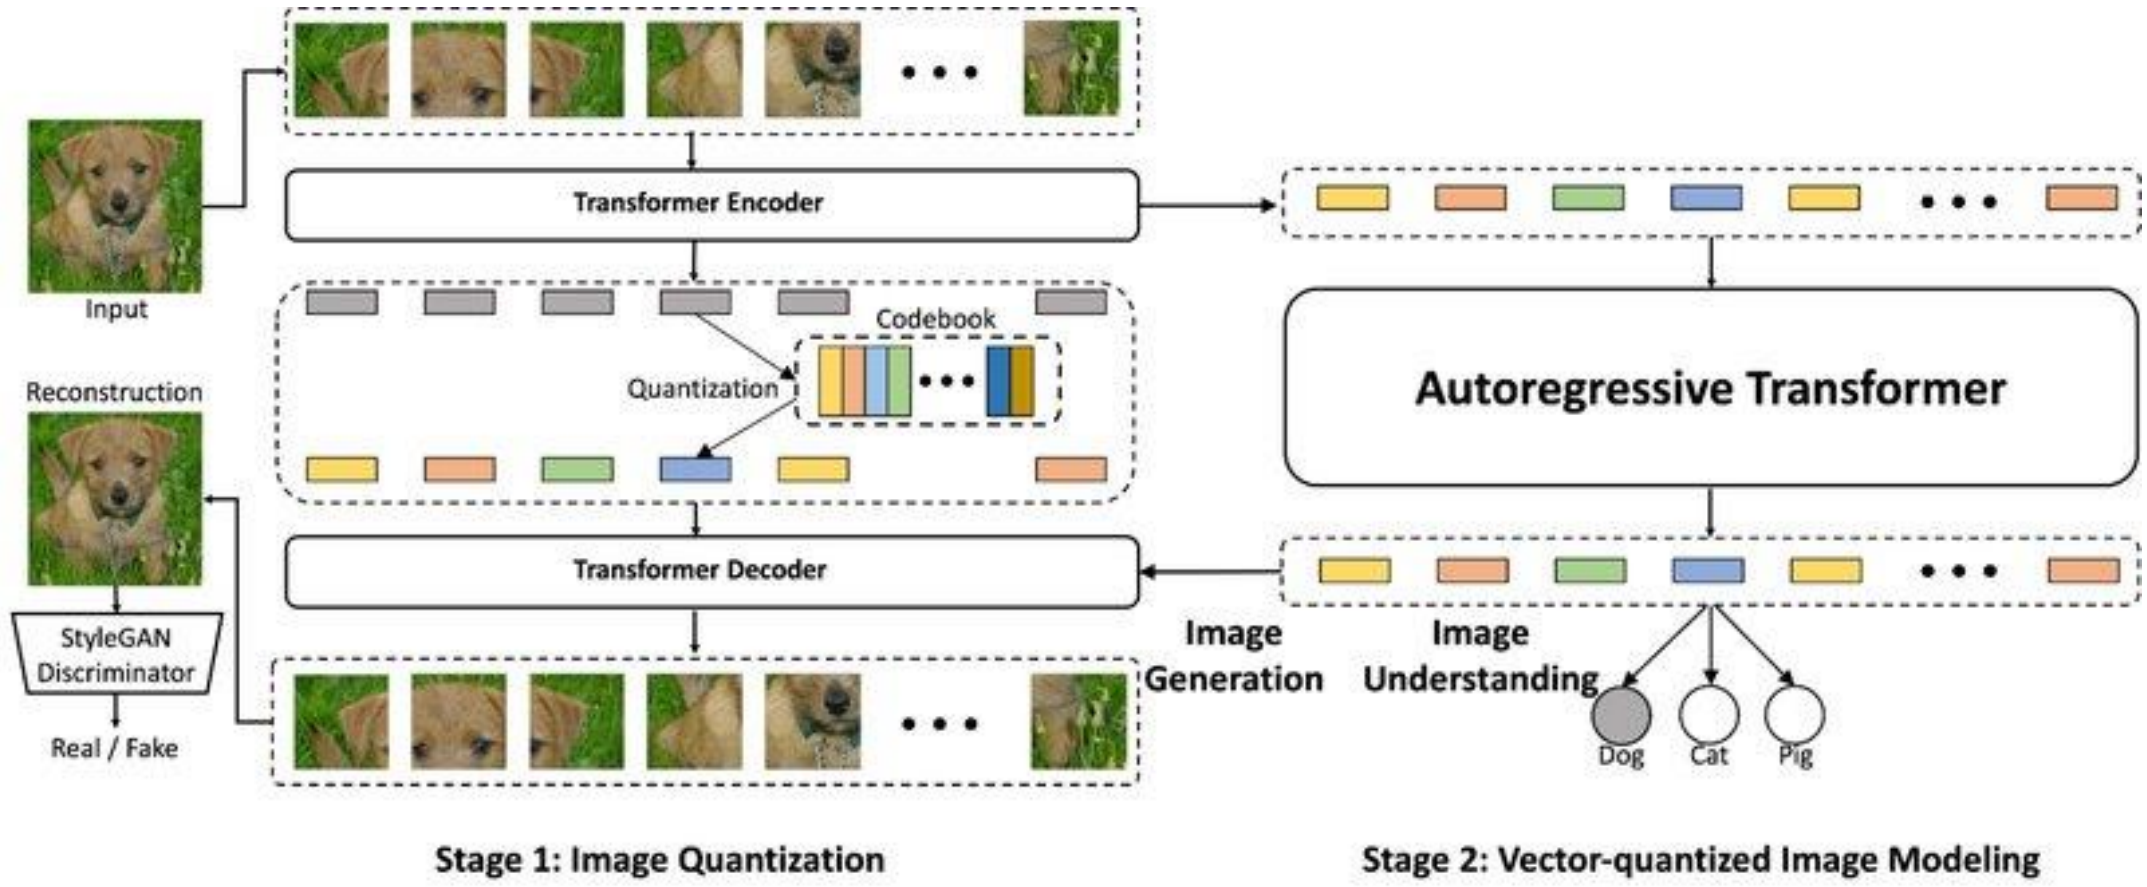

Coarse-to-fine иерархический подход

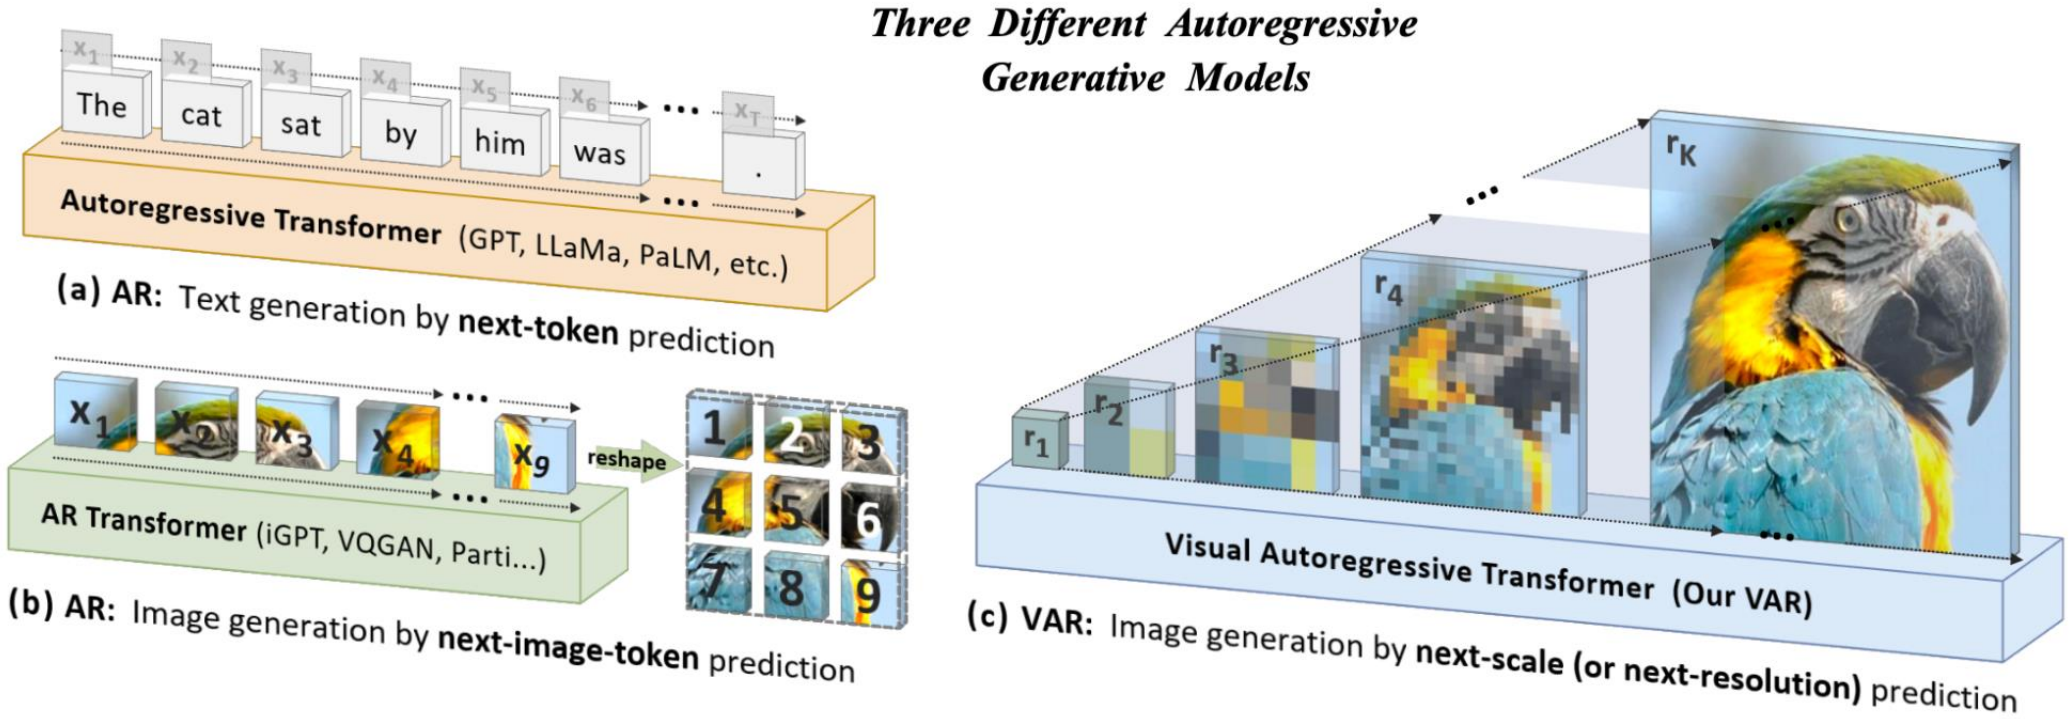

Практика по AR-моделям

https://colab.research.google.com/drive/1EIsBxlTcz3ZB0j-ZxN1gWD2dSQq6krPj?usp=sharing